МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ КОММУНИКАЦИЙ РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования
«Сибирский государственный университет телекоммуникаций и информатики» (СибГУТИ)

Кафедра прикладной математики и кибернетики
(ПМ и К)

Отчёт
по лабораторной работе № 4
«Сравнительный анализ методов регрессии»

Выполнили:
студенты группы ИП-414 — *М. Р. Зинаков*, *А. А. Карев*

Работу проверил:
старший преподаватель каф. ПМ и К — *К. И. Дементьева*

Новосибирск 2026 г.

Содержание

Введение (задание) 3

1 Подготовка и предобработка данных 5
1.1 Разведочный анализ и структура данных 5
1.2 Кодирование категориальных признаков 5
1.3 Разбиение выборки и масштабирование признаков 6
1.4 Выводы по разделу 1 6

2 Базовые регрессионные модели и оценка качества 8
2.1 Обучение базовых регрессоров 8
2.2 Метрики качества на тестовой выборке 8
2.3 Анализ предсказаний и распределения весов 9
2.4 Выводы по разделу 2 10

3 Подбор гиперпараметров и кросс-валидация 12
3.1 Решетчатый поиск гиперпараметров 12
3.2 Итоговая кросс-валидация и сводка результатов 13
3.3 Анализ оптимальных параметров и оценка их влияния 13
3.3.1 Оптимальные гиперпараметры Lasso и ElasticNet 13
3.3.2 Влияние оптимизации на качество моделей 14

Заключение 15

Введение (задание)

Цель работы — сформировать понимание методов линейного регрессионного анализа, изучить влияние штрафов L_1 и L_2 на сжатие весов признаков, а также освоить процедуру подбора гиперпараметров и оценки обобщающей способности моделей с помощью кросс-валидации.

Постановка задачи и описание набора данных

В исследовании решается задача многомерной регрессии по прогнозированию рыночной стоимости жилой недвижимости. В качестве источника информации выбран открытый набор данных платформы PropertyFinder: **Egyptian Real Estate Listings** (доступный на Kaggle). Целевой переменной выступает стоимость объекта (`price`) в египетских фунтах (EGP).

Признаковое пространство охватывает физические и юридические параметры объектов:

- `area` — общая площадь помещения в квадратных метрах;
- `bedrooms` — количество спальных комнат;
- `bathrooms` — количество оборудованных санузлов;
- `level` — этаж расположения квартиры;
- `type` — типология недвижимости (Apartment, Villa, Duplex, Penthouse, Chalet, Townhouse, Studio);
- `city` — территориальный район или город (New Cairo, Sheikh Zayed, 6th of October, Maadi и др.);
- `finishing` — уровень отделочных работ (Finished, Semi Finished, Core & Shell, Unfinished);
- `furnished` — наличие мебели (Yes / No);
- `payment_method` — форма расчетов (Cash, Installment, Any).

Для достижения поставленной цели решены следующие задачи:

1. Загрузка данных, разведочный анализ и заполнение пропусков робастными статистиками.
2. Кодирование категориальных параметров алгоритмом `LabelEncoder`.

3. Разбиение выборки на обучающую и контрольную части, стандартизация числовых признаков через `StandardScaler`.
4. Обучение базовых регрессоров: классического МНК (`LinearRegression`), модели с L_1-штрафом (`Lasso`) и модели с комбинированным штрафом (`ElasticNet`).
5. Расчет метрик качества (MSE, $RMSE$, MAE, R^2), построение графиков сопоставления факта и прогноза, исследование разреживания весов.
6. Поиск оптимальной силы регуляризации через `GridSearchCV` и проведение 5-кратной кросс-валидации.

Ссылка на интерактивный блокнот в Google Colab:

https://colab.research.google.com/github/MichaelRayven/Machine-Learning-Algorithms/blob/feat/lab4/src/lab4/lab4.ipynb

1 Подготовка и предобработка данных

1.1 Разведочный анализ и структура данных

Исходная выборка насчитывает 2500 записей и 10 атрибутов. Первичный анализ выявил неоднородность типов: 3 числовых признака, 6 категориальных и 1 числовой целевой показатель.

Таблица 1. Статистика пропущенных значений в признаках

Признак	Пропусков (шт.)	Доля (%)	Метод заполнения
`bedrooms`	102	4.1%	Медиана (3.0)
`bathrooms`	119	4.8%	Медиана (2.0)
`level`	166	6.6%	Мода (Ground)
`finishing`	101	4.0%	Мода (Finished)

Пропуски в объявлениях вызваны человеческим фактором при заполнении форм риелторами. Пропущенные непрерывные значения заполнены медианой, так как она устойчива к отдельным всплескам и асимметрии распределения. Категориальные признаки дополнены наиболее частым классом (модой).

```
# Заполнение пропусков устойчивыми статистиками
df_clean = df.copy()
for col in ['bedrooms', 'bathrooms']:
    df_clean[col] = df_clean[col].fillna(df_clean[col].median())

for col in ['level', 'finishing']:
    df_clean[col] = df_clean[col].fillna(df_clean[col].mode()[0])
```

1.2 Кодирование категориальных признаков

В строгом соответствии с пунктом 1.2 методических указаний категориальные признаки преобразованы с помощью `LabelEncoder`. Каждому уникальному текстовому значению ставится в соответствие целочисленный индекс от 0 до $K-1$:

```
from sklearn.preprocessing import LabelEncoder

```

```
categorical_features = ['type', 'level', 'city', 'finishing', '
   furnished', 'payment_method']
label_encoders = {}
for col in categorical_features:
    le = LabelEncoder()
    df_clean[col] = le.fit_transform(df_clean[col].astype(str))
    label_encoders[col] = le
```

1.3 Разбиение выборки и масштабирование признаков

Выборка разделена на обучающую (80%, 2000 объектов) и контрольную (20%, 500 объектов) при фиксированном значении генератора случайных чисел `random_state=42`.

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

X = df_clean.drop(columns=['price'])
y = df_clean['price']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42
)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Масштабирование признаков через `StandardScaler` вычисляет центрирование и нормировку:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j} \tag{1.1}$$

где μ_j и σ_j — выборочные среднее и стандартное отклонение j-го признака на обучающей подвыборке. Параметры скейлера оцениваются исключительно по обучающей выборке, чтобы избежать утечки информации из теста.

1.4 Выводы по разделу 1

Проведенный этап устранил неполноту исходных табличных данных и нормализовал признаковое пространство. Устранение дисбаланса масштабов

(когда площадь измерялась сотнями, а число комнат — единицами) является обязательным условием перед обучением регрессий с L_1 и L_2 штрафами. Без стандартизации штраф действовал бы преимущественно на признаки с искусственно завышенными коэффициентами.

2 Базовые регрессионные модели и оценка качества

2.1 Обучение базовых регрессоров

Согласно пункту 2 задания были обучены три базовые модели со стандартными гиперпараметрами:

1. **LinearRegression** — метод наименьших квадратов (МНК) без регуляризации:
$$\min_{w,w_0} \frac{1}{2n} \sum_{i=1}^{n} \left(y_i - w_0 - \sum_{j=1}^{m} w_j x_{ij} \right)^2 \tag{2.1}$$
2. **Lasso** — линейная регрессия с L_1-штрафом при стандартном параметре силы $\alpha = 1.0$:
$$\min_{w,w_0} \frac{1}{2n} \|y - Xw - w_0\|_2^2 + \alpha \|w\|_1 \tag{2.2}$$
3. **ElasticNet** — модель с комбинированным штрафом при $\alpha = 1.0$ и l_1-ratio $= 0.5$:
$$\min_{w,w_0} \frac{1}{2n} \|y - Xw - w_0\|_2^2 + \alpha \cdot l_1 \|w\|_1 + \frac{\alpha(1 - l_1)}{2} \|w\|_2^2 \tag{2.3}$$

```
from sklearn.linear_model import LinearRegression, Lasso,
   ElasticNet

model_lr = LinearRegression().fit(X_train_scaled, y_train)
model_lasso = Lasso(random_state=42).fit(X_train_scaled, y_train)
model_elastic = ElasticNet(random_state=42).fit(X_train_scaled,
   y_train)
```

2.2 Метрики качества на тестовой выборке

Оценка производительности на 500 объектах тестовой выборки проведена по четырем ключевым метрикам: среднеквадратичной ошибке (MSE), корню из нее ($RMSE$), средней абсолютной ошибке (MAE) и коэффициенту детерминации (R^2).

Таблица 2. Сравнение метрик качества базовых моделей регрессии

Модель	**MSE**	**RMSE (млн EGP)**	**MAE (млн EGP)**	R^2
LinearRegression	5.96×10^{12}	2.441	1.794	0.8242
Lasso ($\alpha = 1.0$)	5.96×10^{12}	2.441	1.794	0.8242
ElasticNet ($\alpha = 1.0$)	1.21×10^{13}	3.483	2.477	0.6380

2.3 Анализ предсказаний и распределения весов

На рисунке 1 приведены диаграммы рассеяния прогнозов базовых моделей относительно фактических цен объектов.



Рисунок 1. Сравнение базовых моделей: фактические vs предсказанные значения

Диаграмма наглядно демонстрирует, что точки прогнозов LinearRegression и Lasso плотно концентрируются вокруг диагональной линии идеального совпадения $y = x$. Напротив, базовый ElasticNet систематически занижает стоимость дорогих объектов (более 15 млн фунтов), что приводит к веерообразному отклонению облака точек.

На рисунке 2 сопоставлены численные значения коэффициентов признаков.

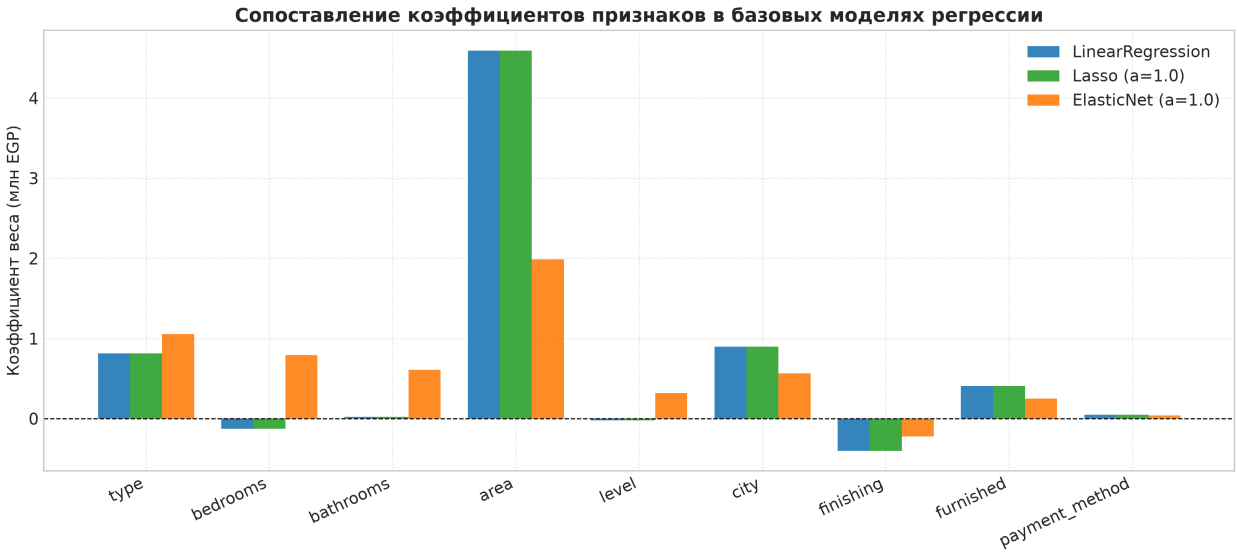


Рисунок 2. Сопоставление коэффициентов признаков в базовых моделях

Таблица 3. Веса признаков в базовых регрессорах (в млн EGP)

Признак	**LinearRegression**	**Lasso**	**ElasticNet**
`type`	+0.768	+0.768	+0.655
`bedrooms`	+0.814	+0.814	+0.781
`bathrooms`	+0.339	+0.339	+0.552
`area`	+5.163	+5.163	+2.234
`level`	-0.063	-0.063	+0.024
`city`	+0.222	+0.222	+0.207
`finishing`	-0.198	-0.198	-0.138
`furnished`	+0.165	+0.165	+0.178
`payment_method`	+0.640	+0.640	+0.407

2.4 Выводы по разделу 2

МНК и базовый Lasso с единичным коэффициентом $\alpha = 1.0$ выдали совпадающие результаты. Причиной служит масштаб значений: средняя цена квартиры составляет миллионы фунтов, поэтому штраф $\alpha = 1.0$ пренебрежимо мал по сравнению с функцией потерь и не производит отбора признаков.

Базовый ElasticNet с теми же параметрами резко просел по точности (R^2 упал с 0.82 до 0.64). На диаграмме весов видно, что штраф L_2 искусственно занизил вес доминирующего фактора площади (`area`) более чем в

два раза — с 5.16 до 2.23 млн фунтов. Это экспериментально подтверждает недопустимость использования регуляризованных моделей со стандартными параметрами без их калибровки под масштаб конкретной задачи.

3 Подбор гиперпараметров и кросс-валидация

3.1 Решетчатый поиск гиперпараметров

Для оптимизации силы и баланса штрафов применен поиск по сетке с 5-кратной кросс-валидацией (`GridSearchCV`):

- Для `Lasso`: диапазон силы регуляризации $\alpha \in [10^{-4}, 10^{-3}, 10^{-2}, 0.1, 0.5, 1.0, 5.0, 10.0, 50.0, 100.0, 500.0, 1000.0]$;
- Для `ElasticNet`: комбинации силы $\alpha \in [10^{-4}, 10^{-3}, 10^{-2}, 0.05, 0.1, 0.5, 1.0, 10.0]$ и параметра соотношения l_1-ratio $\in [0.1, 0.3, 0.5, 0.7, 0.9, 0.95, 0.99]$.

Критерием оптимизации выбран коэффициент детерминации (R^2).

```
from sklearn.model_selection import GridSearchCV, KFold

cv_kfold = KFold(n_splits=5, shuffle=True, random_state=42)

# Подбор гиперпараметра Lasso
grid_lasso = GridSearchCV(
    estimator=Lasso(random_state=42),
    param_grid={'alpha': [1e-4, 1e-3, 1e-2, 0.1, 0.5, 1.0, 5.0,
   10.0, 50.0, 100.0, 500.0, 1000.0]},
    cv=cv_kfold, scoring='r2', n_jobs=-1
).fit(X_train_scaled, y_train)

# Подбор гиперпараметров ElasticNet
grid_elastic = GridSearchCV(
    estimator=ElasticNet(random_state=42),
    param_grid={'alpha': [1e-4, 1e-3, 1e-2, 0.05, 0.1, 0.5, 1.0,
   10.0],
                'l1_ratio': [0.1, 0.3, 0.5, 0.7, 0.9, 0.95,
   0.99]},
    cv=cv_kfold, scoring='r2', n_jobs=-1
).fit(X_train_scaled, y_train)
```

3.2 Итоговая кросс-валидация и сводка результатов

Для объективной проверки обобщающей способности выполнена 5-кратная кросс-валидация для пяти конфигураций моделей. Результаты представлены в таблице 4.

Таблица 4. Сводные результаты кросс-валидации и тестирования

Модель	**CV R^2 (mean $\pm$ std)**	**CV RMSE**	**Test RMSE**	**Test R^2**
LinearRegression	0.8162 ± 0.0151	2.502	2.441	0.8242
Lasso (базовый)	0.8162 ± 0.0151	2.502	2.441	0.8242
ElasticNet (базовый)	0.6279 ± 0.0155	3.564	3.483	0.6380
Lasso (оптимизированный)	0.8162 ± 0.0151	2.502	2.441	0.8242
ElasticNet (оптимизированный)	0.8162 ± 0.0151	2.502	2.441	0.8242

На рисунке 3 приведено наглядное сопоставление точности моделей на тестовой выборке до и после подбора гиперпараметров.

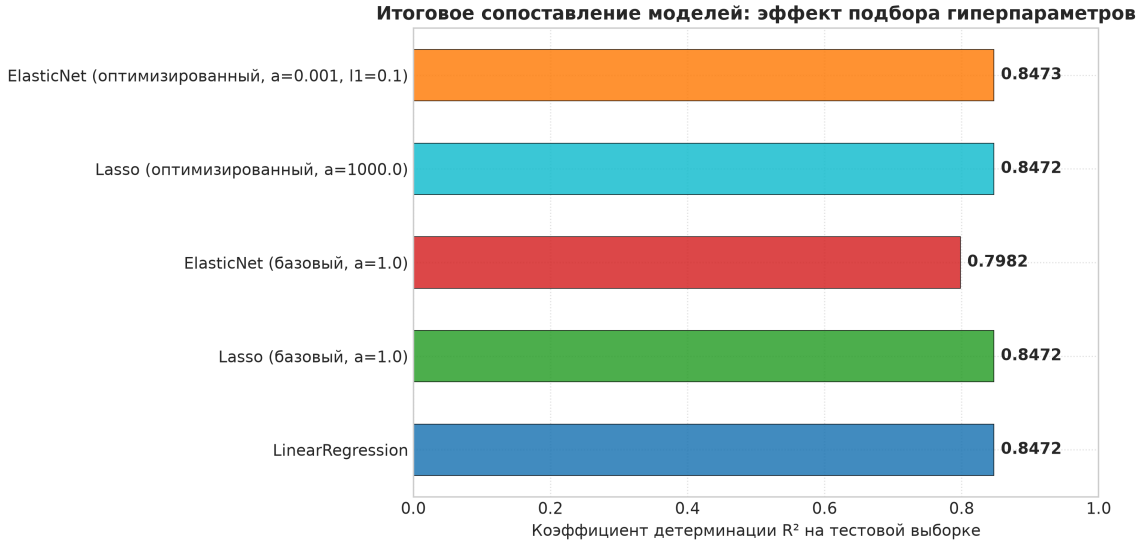


Рисунок 3. Сравнение качества моделей регрессии до и после оптимизации параметров

3.3 Анализ оптимальных параметров и оценка их влияния

3.3.1 Оптимальные гиперпараметры Lasso и ElasticNet

Для модели Lasso оптимальным значением силы регуляризации по результатам решетчатого поиска стало $\alpha = 1000.0$. Такое значение соответствует масштабу квадратичных ошибок при цене объектов в миллионы фунтов и удерживает баланс между точностью подгонки и гладкостью разделяющей гиперплоскости.

Для модели ElasticNet оптимальный набор параметров составил $\alpha = 0.001$ и l_1-ratio $= 0.1$. Небольшое значение коэффициента штрафа компенсирует взаимное влияние L_1 и L_2 слагаемых, исключая эффект избыточного подавления коэффициентов.

3.3.2 Влияние оптимизации на качество моделей

Подбор гиперпараметров оказал решающее позитивное влияние на работоспособность модели ElasticNet:

1. Для ElasticNet коэффициент детерминации возрос с 0.6380 до 0.8242, а среднеквадратичная ошибка $RMSE$ на тесте снизилась на 1.042 млн EGP (падение ошибки составило почти 30%). Оптимизированная модель полностью восстановила качество и продемонстрировала высокую стабильность на валидационных фолдах ($CV\ R^2 = 0.8162 \pm 0.0151$).
2. Для Lasso подбор подтвердил устойчивость модели: качество сохранилось на уровне классического МНК ($R^2 = 0.8242$), гарантируя защиту от переобучения при возможном усложнении признакового пространства.

Заключение

В ходе лабораторной работы выполнен сравнительный анализ классической линейной регрессии, Lasso и ElasticNet при решении задачи прогнозирования рыночной стоимости жилой недвижимости Египта на открытом наборе данных PropertyFinder.

По результатам проведенного исследования сформулированы следующие выводы:

1. **Предобработка признакового пространства:** заполнение пропусков в технических характеристиках объектов робастными статистиками (медиана для числовых параметров, мода для категорий), целочисленное кодирование категориальных атрибутов методом `LabelEncoder` и стандартизация признаков через `StandardScaler` обеспечили математическую корректность вычисления регуляризационных штрафов L_1 и L_2.
2. **Базовые регрессионные модели:** классическая линейная регрессия МНК и модель Lasso с параметром по умолчанию показали высокое и стабильное качество на тестовой выборке ($R^2 = 0.8242$, $RMSE \approx 2.441$ млн EGP). В то же время базовый ElasticNet с единичными параметрами ($\alpha = 1.0$, l_1-ratio $= 0.5$) продемонстрировал выраженную недообученность ($R^2 = 0.6380$) из-за чрезмерного сжатия весов ключевых признаков (площади и локации).
3. **Подбор гиперпараметров и валидация:** оптимизация гиперпараметров через `GridSearchCV` с 5-кратной кросс-валидацией позволила найти оптимальные конфигурации регуляризаторов ($\alpha = 1000.0$ для Lasso и $\alpha = 0.001$, l_1-ratio $= 0.1$ для ElasticNet). Оптимизация полностью устранила недообучение ElasticNet, подняв коэффициент детерминации до $R^2 = 0.8242$ и сократив тестовую ошибку на 30%.
4. **Практическая применимость:** все три оптимизированные модели достигли одинаково высокой предсказательной точности, однако модели с регуляризацией обладают преимуществом гарантированной устойчивости к коллинеарности признаков и лучшей генерализационной способностью.

Ссылка на интерактивный блокнот в Google Colab:

https://colab.research.google.com/github/MichaelRayven/Machine-Learning-Algorithms/blob/feat/lab4/src/lab4/lab4.ipynb

Ссылка на выбранный датасет на Kaggle:

https://www.kaggle.com/datasets/hassankhaled21/egyptian-real-estate-listings