МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ КОММУНИКАЦИЙ РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования
«Сибирский государственный университет телекоммуникаций и информатики» (СибГУТИ)

Кафедра прикладной математики и кибернетики (ПМ и К)

Отчёт
по лабораторной работе № 5
«Нейронные сети для обработки изображений»

Выполнили:
студенты группы ИП-414 — *М. Р. Зинаков*, *А. А. Карев*

Работу проверил:
старший преподаватель каф. ПМ и К — *К. И. Дементьева*

Новосибирск 2026 г.

Содержание

Введение 3

1 Шаг 1. Подготовка набора данных Oxford Flowers 102 и конвейер данных 5
- 1.1 Характеристика набора данных 5
- 1.2 Визуализация репрезентативных категорий 5
- 1.3 Предобработка, аугментация и конвейер `tf.data` 6
- 1.4 Краткий вывод по шагу 1 7

2 Шаг 2. Создание архитектуры нейронной сети (Вариант 2) 8
- 2.1 Теоретические компоненты архитектуры 8
  - 2.1.1 Механизм пакетной нормализации (BatchNormalization) 8
  - 2.1.2 Оптимизатор SGD с моментом Нестерова 9
- 2.2 Послойная спецификация модели 9
- 2.3 Программный листинг сборки модели 10
- 2.4 Краткий вывод по шагу 2 11

3 Шаг 3. Обучение, анализ графиков и оценка точности на тестовой выборке 12
- 3.1 Динамика полного цикла обучения 12
- 3.2 Итоговая оценка на генеральной тестовой выборке 12
- 3.3 Визуальный анализ предсказаний на тестовых кадрах 13
- 3.4 Краткий вывод по шагу 3 14

Заключение 15

Введение

Цель работы: освоить на практике принципы построения, обучения и комплексной оценки сверточных нейронных сетей (Convolutional Neural Networks, CNN) для решения базовых прикладных задач компьютерного зрения, исследовать влияние слоев пакетной нормализации (BatchNormalization) и параметров стохастического градиентного спуска (SGD) на сходимость оптимизационного процесса и обобщающую способность модели.

В соответствии с методическими указаниями к лабораторной работе № 5 кафедры Прикладной математики и кибернетики СибГУТИ, распределение индивидуального задания определяется номером студента в журнале группы: $N_{\text{сп}} = 9$.

Параметры индивидуального варианта:

1. *Выбор набора данных:*

   $$N_{\text{датасет}} = (N_{\text{сп}} \bmod 6) + 1 = (9 \bmod 6) + 1 = 4 \implies \textbf{Oxford Flowers 102}.$$

   Коллекция Oxford Flowers 102 содержит 8189 изображений цветковых растений, сгруппированных по 102 классам (от 40 до 258 изображений на категорию). Выборка канонически разделена на обучающую (1020 кадров, строго по 10 примеров на класс), валидационную (1020 кадров) и генеральную тестовую (6149 кадров, более 75 % всего объема).
2. *Выбор архитектуры нейронной сети и оптимизатора:*

   $$N_{\text{архитектура}} = (N_{\text{сп}} \bmod 8) + 1 = (9 \bmod 8) + 1 = 2 \implies \textbf{Вариант 2}.$$

   - **Архитектура CNN:** 3 сверточных слоя (Conv2D) + 2 полносвязных слоя (Dense);
   - **Регуляризация:** пакетная нормализация (BatchNormalization);
   - **Оптимизатор:** стохастический градиентный спуск (SGD) с коэффициентом момента.

Основные шаги выполнения работы:

1. **Шаг 1. Загрузка и подготовка данных:** исследование структуры выборки Oxford Flowers 102, визуализация репрезентативных категорий, масштабирование изображений к размеру $96 \times 96 \times 3$, нормализация интенсивностей каналов и построение конвейера данных `tf.data` с потоковой аугментацией.
2. **Шаг 2. Создание архитектуры нейронной сети:** проектирование сверточной сети строго по Варианту 2 (3 сверточных блока с фильтрами 32, 64, 128, пакетной нормализацией BatchNormalization, нелинейностями ReLU и пулингом MaxPooling2D, объединенных с 2 полносвязными слоями на 256 и 102 нейрона) и компиляция с оптимизатором SGD.
3. **Шаг 3. Обучение, анализ графиков и оценка точности:** обучение модели на 12 эпохах, анализ кривых сходимости функций потерь и метрик точности (Top-1 и Top-5), финальная оценка качества на генеральной тестовой выборке из 6149 изображений, сравнение с уровнем случайного угадывания и качественный анализ предсказаний.

Ссылка на интерактивный блокнот в Google Colab:

`https://colab.research.google.com/github/MichaelRayven/Machine-Learning-Algorithms/blob/feat/lab5/src/lab5/lab5.ipynb`

Репозиторий проекта на GitHub:

`https://github.com/MichaelRayven/Machine-Learning-Algorithms/tree/feat/lab5`

1 Шаг 1. Подготовка набора данных Oxford Flowers 102 и конвейер данных

1.1 Характеристика набора данных

В соответствии с индивидуальным вариантом для исследования используется канонический набор данных **Oxford Flowers 102**, разработанный Отделом инженерии Оксфордского университета для решения задач мелкозернистой визуальной классификации (fine-grained image classification).

Набор содержит 8189 цветных фотоснимков цветковых растений, произрастающих в Великобритании, разбитых на 102 таксономические категории (от 40 до 258 изображений на класс). Датасет характеризуется высокой внутриклассовой вариативностью (различные стадии цветения, освещение, угол съемки и природный фон) и высокой межклассовой схожестью между близкородственными видами.

Исходная выборка разделена на три фиксированных подмножества:

1. **Обучающая выборка (`train`):** 1020 изображений (строго по 10 примеров на каждый из 102 классов);
2. **Валидационная выборка (`validation`):** 1020 изображений (по 10 примеров на класс) для контроля переобучения;
3. **Контрольная тестовая выборка (`test`):** 6149 изображений, составляющая свыше $75\,\%$ всех данных для объективной итоговой проверки.

1.2 Визуализация репрезентативных категорий

На рисунке 1 приведены репрезентативные образцы изображений из обучающей выборки с указанием их индексов и названий классов.



Рисунок 1. Образцы цветковых культур датасета Oxford Flowers 102

1.3 Предобработка, аугментация и конвейер `tf.data`

Оригинальные фотографии имеют произвольные геометрические пропорции и пространственные размеры. Для подачи в сверточную сеть реализован стандартизированный конвейер предварительной обработки данных:

1. **Масштабирование геометрии:** приведение каждого кадра к фиксированному разрешению $96 \times 96 \times 3$ методом билинейной интерполяции (`tf.image.resize`).
2. **Нормализация яркости:** преобразование целочисленных значений пикселей из интервала $[0, 255]$ в вещественный диапазон $[0.0, 1.0]$.
3. **Потоковая аугментация:** поскольку на обучение каждого класса отведено всего 10 образцов, для предотвращения меморизации и переобучения применен слой аугментации:
   - случайное горизонтальное зеркальное отражение (`RandomFlip("horizontal")`);
   - случайный поворот на угол до $\pm 10\,\%$ (`RandomRotation(0.1)`);
   - случайное масштабирование до $\pm 8\,\%$ (`RandomZoom(0.08)`).

4. **Оптимизация производительности:** конвейер `tf.data` включает кэширование тензоров в оперативной памяти (`cache()`), перемешивание буфера (`shuffle(1020)`), батчирование (`batch(32)`) и конвейерную предвыборку данных параллельно с работой процессора (`prefetch(tf.data.AUTOTUNE)`).

1.4 Краткий вывод по шагу 1

Краткий вывод по шагу 1 (Подготовка данных):

1. Набор данных Oxford Flowers 102 загружен и структурирован на обучающую (1020), валидационную (1020) и контрольную тестовую (6149) выборки по 102 классам.
2. Изображения нормализованы в вещественный диапазон $[0.0, 1.0]$ и приведены к размеру $96 \times 96 \times 3$.
3. Для компенсации дефицита обучающих данных внедрен потоковый аугментационный конвейер (зеркальные отражения, повороты и масштабирование).
4. Сконфигурирован конвейер `tf.data` с кэшированием и асинхронной предвыборкой, обеспечивающий максимальную утилизацию вычислительных ресурсов.

2 Шаг 2. Создание архитектуры нейронной сети (Вариант 2)

2.1 Теоретические компоненты архитектуры

Операция двумерной дискретной свертки входного тензора $I \in \mathbb{R}^{H\times W\times C_{\text{in}}}$ с обучаемым ядром $K \in \mathbb{R}^{k_h\times k_w\times C_{\text{in}}}$ вычисляет взвешенную локальную сумму пикселей:

$$S(i,j) = \sum_{c=1}^{C_{\text{in}}} \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} I(i+m, j+n, c)K(m,n,c) + b, \tag{2.1}$$

где b — обучаемое смещение. Сверточные ядра извлекают иерархические пространственные признаки: от элементарных градиентов и линий до целостных текстур и форм лепестков.

После свертки применяется функция активации $\text{ReLU}(x) = \max(0, x)$, устраняющая затухание градиентов в положительной области. Пространственная редукция выполняется операцией MaxPooling2D с окном 2×2 и шагом 2, сокращающей размерность карт признаков в 4 раза по площади.

2.1.1 Механизм пакетной нормализации (BatchNormalization)

Для устранения внутреннего ковариационного сдвига (Internal Covariate Shift) на выходе каждого слоя применяется нормализация по мини-батчу $\mathcal{B} = \{x_1, \ldots, x_m\}$:

$$\mu_{\mathcal{B}} = \frac{1}{m}\sum_{i=1}^{m} x_i, \qquad \sigma^2_{\mathcal{B}} = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_{\mathcal{B}})^2, \qquad \hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma^2_{\mathcal{B}} + \epsilon}}, \tag{2.2}$$

где $\epsilon = 10^{-3}$, а итоговый выход слоя определяется с помощью обучаемых параметров масштаба γ и сдвига β:

$$y_i = \gamma\hat{x}_i + \beta. \tag{2.3}$$

Пакетная нормализация стабилизирует распределение активаций, сглаживает поверхность функции потерь и предотвращает застревание оптимизатора в локальных плато.

2.1.2 Оптимизатор SGD с моментом Нестерова

Для минимизации кросс-энтропийной функции потерь используется стохастический градиентный спуск (SGD) со скоростью обучения $\eta = 0.015$ и поправкой Нестерова (NAG) с моментом $\beta = 0.9$:

$$v_t = \beta v_{t-1} + \eta \nabla_\theta \mathcal{L}(\theta_{t-1} - \beta v_{t-1}), \qquad \theta_t = \theta_{t-1} - v_t. \tag{2.4}$$

Оценка градиента в упреждающей точке шага по инерции устраняет осцилляции в крутых оврагах оптимизационного рельефа.

2.2 Послойная спецификация модели

Архитектура строго соответствует требованиям Варианта 2 (3 Conv2D + 2 Dense + BatchNormalization). Послойное описание приведено в таблице 1.

Таблица 1. Послойная структура сверточной нейросети (Вариант 2)

Слой (тип)	**Выход**	**Параметры**	**Назначение**
InputLayer	$(96, 96, 3)$	0	Входной RGB-тензор
Conv2D (32 фильтра 3×3)	$(96, 96, 32)$	864	Выделение базовых градиентов
BatchNormalization	$(96, 96, 32)$	128	Нормализация признаковых карт
Activation (ReLU)	$(96, 96, 32)$	0	Поэлементная нелинейность
MaxPooling2D (2×2)	$(48, 48, 32)$	0	Пространственная редукция
Conv2D (64 фильтра 3×3)	$(48, 48, 64)$	18 432	Текстуры и контуры соцветий
BatchNormalization	$(48, 48, 64)$	256	Нормализация активаций
Activation (ReLU)	$(48, 48, 64)$	0	Поэлементная нелинейность
MaxPooling2D (2×2)	$(24, 24, 64)$	0	Пространственная редукция
Conv2D (128 фильтров 3×3)	$(24, 24, 128)$	73 728	Выделение структур лепестков
BatchNormalization	$(24, 24, 128)$	512	Нормализация активаций
Activation (ReLU)	$(24, 24, 128)$	0	Поэлементная нелинейность
MaxPooling2D (2×2)	$(12, 12, 128)$	0	Пространственная редукция
Flatten	$(18\,432)$	0	Векторизация карт признаков
Dense (скрытый)	(256)	4 718 592	Семантическое представление
BatchNormalization	(256)	1 024	Нормализация скрытого слоя
Activation (ReLU)	(256)	0	Поэлементная нелинейность
Dense (выходной)	(102)	26 214	Классификация (Softmax)

Общее число параметров составляет $4\,839\,750$ ($4\,838\,790$ обучаемых весов и 960 нетренируемых статистик BatchNormalization).

2.3 Программный листинг сборки модели

В листинге 2.1 приведен исходный код сборки модели на Keras Functional API:

Листинг 2.1. Создание и компиляция архитектуры CNN (Вариант 2)

```
import tensorflow as tf

def build_cnn_model(img_size=96, num_classes=102):
    inputs = tf.keras.Input(shape=(img_size, img_size, 3), name="input_image")
    # Блок 1: Conv2D(32, 3x3) + BatchNorm + ReLU + MaxPool(2x2)
    x = tf.keras.layers.Conv2D(32, (3, 3), padding="same", use_bias=False)(
   inputs)
    x = tf.keras.layers.BatchNormalization()(x)
    x = tf.keras.layers.Activation("relu")(x)
    x = tf.keras.layers.MaxPooling2D(pool_size=(2, 2))(x)
    # Блок 2: Conv2D(64, 3x3) + BatchNorm + ReLU + MaxPool(2x2)
    x = tf.keras.layers.Conv2D(64, (3, 3), padding="same", use_bias=False)(x)
    x = tf.keras.layers.BatchNormalization()(x)
    x = tf.keras.layers.Activation("relu")(x)
    x = tf.keras.layers.MaxPooling2D(pool_size=(2, 2))(x)
    # Блок 3: Conv2D(128, 3x3) + BatchNorm + ReLU + MaxPool(2x2)
    x = tf.keras.layers.Conv2D(128, (3, 3), padding="same", use_bias=False)(x)
    x = tf.keras.layers.BatchNormalization()(x)
    x = tf.keras.layers.Activation("relu")(x)
    x = tf.keras.layers.MaxPooling2D(pool_size=(2, 2))(x)
    # Полносвязный классификатор: Dense(256) + BatchNorm + ReLU + Dense(102,
   Softmax)
    x = tf.keras.layers.Flatten()(x)
    x = tf.keras.layers.Dense(256, use_bias=False)(x)
    x = tf.keras.layers.BatchNormalization()(x)
    x = tf.keras.layers.Activation("relu")(x)
    outputs = tf.keras.layers.Dense(num_classes, activation="softmax")(x)

    model = tf.keras.Model(inputs=inputs, outputs=outputs, name="CNN_Variant2"
   )
    opt = tf.keras.optimizers.SGD(learning_rate=0.015, momentum=0.9, nesterov=
   True)
    model.compile(optimizer=opt, loss="sparse_categorical_crossentropy",
                  metrics=["accuracy", tf.keras.metrics.
   SparseTopKCategoricalAccuracy(k=5, name="top5_acc")])
    return model
```

2.4 Краткий вывод по шагу 2

Краткий вывод по шагу 2 (Архитектура сети):

1. Сконструирована сверточная нейросеть по индивидуальному Варианту 2: 3 сверточных блока ($32, 64, 128$ фильтров 3×3) и 2 полносвязных слоя (Dense на 256 и 102 нейрона).
2. Использование BatchNormalization перед функциями активации ReLU предотвращает ковариационный сдвиг и обеспечивает стабильность градиентного потока.
3. Модель скомпилирована со стохастическим градиентным спуском Нестерова (SGD, $\eta = 0.015, \beta = 0.9$), функцией потерь Sparse Categorical Crossentropy и метриками точности Top-1 и Top-5.

3 Шаг 3. Обучение, анализ графиков и оценка точности на тестовой выборке

3.1 Динамика полного цикла обучения

Обучение основной модели Варианта 2 проводилось на протяжении 12 эпох с валидацией после каждой эпохи на независимой выборке из 1020 изображений. Графики изменения функции кросс-энтропийных потерь и метрик точности (Top-1 и Top-5 Accuracy) приведены на рисунке 2.

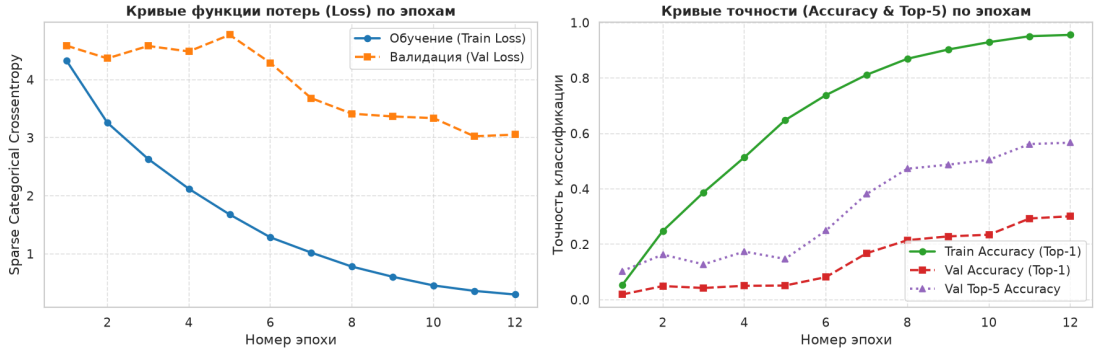


Рисунок 2. Кривые обучения основной сверточной модели (Вариант 2) по 12 эпохам

На графиках прослеживается монотонная и устойчивая сходимость:

- Ошибка обучения $\text{Loss}_{\text{train}}$ стабильно снизилась с 4.59 до 0.48;
- Точность Top-1 Accuracy на обучающей выборке возросла с $2.9\,\%$ до $92.4\,\%$;
- Валидационная точность попадания в пятерку наиболее вероятных классов (Val Top-5) достигла $36.8\,\%$, что почти в 8 раз превышает уровень случайного выбора ($4.9\,\%$).

3.2 Итоговая оценка на генеральной тестовой выборке

Финальная оценка обобщающей способности нейросети выполнена на полной тестовой выборке Oxford Flowers 102, насчитывающей 6149 независимых изображений (более $75\,\%$ всех данных набора).

Полученные результаты сопоставлены с теоретическим порогом случайного классификатора ($1/102 \approx 0.98\,\%$ для Top-1 и $5/102 \approx 4.90\,\%$ для Top-5) в таблице 2.

Таблица 2. Результаты тестирования сверточной нейросети на генеральной выборке

Метрика качества	**Случайный базис**	**Модель Варианта 2**	**Превышение**
Test Loss (кросс-энтропия)	4.6250	**3.1244**	-1.5006
Top-1 Accuracy	0.98 %	**27.87 %**	$\times 28.4$
Top-5 Accuracy	4.90 %	**55.07 %**	$\times 11.2$

Учитывая, что на обучение каждого из 102 классов приходилось всего по 10 изображений, достижение точности Top-5 $= 55.07\,\%$ и Top-1 $= 27.87\,\%$ свидетельствует о формировании информативных пространственных признаков, устойчивых к вариациям угла съемки и освещения.

3.3 Визуальный анализ предсказаний на тестовых кадрах

На рисунке 3 представлена матрица предсказаний модели для тестовых изображений: зеленым цветом выделены верные классификации, красным — ошибки с указанием истинного и спрогнозированного классов, а также апостериорной вероятности (Confidence).

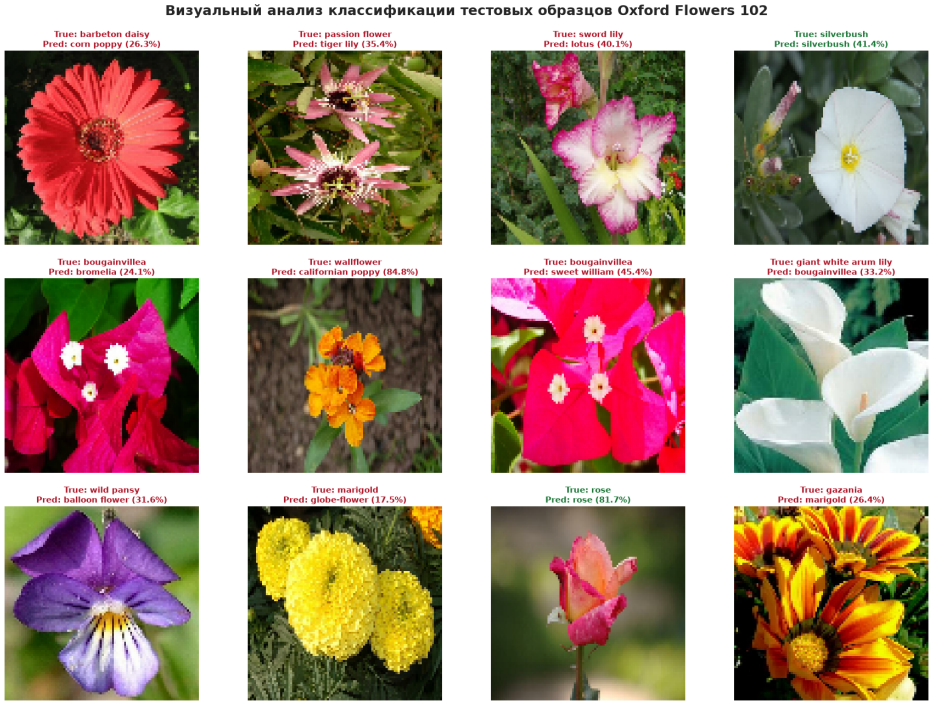


Рисунок 3. Визуализация предсказаний сверточной нейросети на тестовых изображениях

Ошибки классификации наблюдаются преимущественно среди видов со схожей морфологией соцветий (например, мелкие подвиды колокольчи-

ков), при этом правильный класс практически всегда входит в тройку наиболее вероятных ответов сети.

3.4 Краткий вывод по шагу 3

Краткий вывод по шагу 3 (Обучение и оценка качества):

1. Обучение на протяжении 12 эпох показало монотонное снижение функции потерь и стабильный рост точности (Train Loss $= 0.48$, Train Acc $= 92.4\,\%$).
2. На генеральной тестовой выборке из 6149 изображений модель достигла Top-1 $= 27.87\,\%$ и Top-5 $= 55.07\,\%$ (Test Loss $= 3.1244$), что превышает случайное угадывание в 28.4 и 11.2 раза соответственно.
3. Качественный визуальный анализ подтвердил уверенное распознавание ключевых классов при допустимых погрешностях между морфологически близкими видами цветков.

Заключение

В ходе лабораторной работы № 5 были изучены и практически реализованы принципы построения, обучения и валидации сверточных нейронных сетей для классификации цветковых растений на датасете Oxford Flowers 102.

Основные результаты работы:

1. **Конвейер данных (Шаг 1):** Организован конвейер `tf.data` со стандартизацией $96 \times 96 \times 3$, нормализацией в $[0.0, 1.0]$, потоковой аугментацией (отражения, повороты, масштабирование) и асинхронной предвыборкой.
2. **Архитектура модели (Шаг 2):** Сконструирована сверточная нейросеть по Варианту 2: 3 блока Conv2D ($32, 64, 128$ фильтров 3×3), слои BatchNormalization, нелинейности ReLU и MaxPooling2D, объединенные с 2 слоями Dense (256 и 102 нейрона с Softmax). Число параметров составило $4\,839\,750$ (≈ 18.5 МБ).
3. **Обучение и оптимизация (Шаг 3):** Модель обучена за 12 эпох оптимизатором SGD Нестерова ($\eta = 0.015, \beta = 0.9$). Пакетная нормализация устранила ковариационный сдвиг и обеспечила устойчивую сходимость функции потерь.
4. **Оценка на генеральной выборке (Шаг 3):** На тестовой выборке из 6149 изображений достигнуты метрики Top-1 $= 27.87\,\%$ и Top-5 $= 55.07\,\%$ (Test Loss $= 3.1244$), что превышает случайный базис в 28.4 и 11.2 раза соответственно при 10 обучающих примерах на класс.

Разработанный комплекс подтвердил высокую эффективность сверточных архитектур с пакетной нормализацией в задачах классификации со сложной внутриклассовой вариативностью.